

detectar el problema de clasificación y definirlo, implica describir con menos de 10 palabras este.

1.- Realice un análisis exploratorio de datos. Al menos 3 tareas.

Tarea 1:

La primera tarea consiste en cargar los datos desde el archivo de origen y estandarizar su formato. El archivo original presenta particularidades en su estructura (filas de encabezado técnico, columnas de separación vacías e información estadística al final del documento) que deben ser depuradas antes del análisis.

Tarea 2:

La segunda tarea consiste en un problema de clasificación, es imperativo conocer la distribución de la variable objetivo NSP. Esto determinará si nos enfrentamos a un problema de clases balanceadas o desbalanceadas, lo cual impactará directamente en la elección de métricas y estrategias de entrenamiento.

Tarea 3:

La tercera tarea es entender qué variables aportan más información para discriminar el estado fetal, se realiza un análisis bivariado de una característica clínica clave, como la Variabilidad Anormal a Corto Plazo (ASTV), y se construye una matriz de correlación térmica para identificar colinealidad y poder predictivo.

2.- Defina el problema de clasificación.

Definimos formalmente el problema de Machine Learning:

- **Tipo de Problema:** Clasificación Multiclase.
- **Contexto:** El diagnóstico se basa en señales de Cardiotocografía (CTG), que miden simultáneamente la frecuencia cardíaca fetal y las contracciones uterinas.
 - **Variable Objetivo (Y):** La etiqueta NSP (Fetal state class code).
 - **1:** Normal.
 - **2:** Suspect (Sospechoso).
 - **3:** Pathologic (Patológico).
- **Variables Predictoras (X):** 21 variables técnicas extraídas de los trazados de CTG, tales como:
 - LB: Frecuencia cardíaca fetal basal (latidos por minuto).
 - AC: Aceleraciones por segundo.

- UC: Contracciones uterinas por segundo.
- ASTV: Porcentaje de tiempo con variabilidad anormal a corto plazo.
- **Meta:** Construir un modelo predictivo que, dados los valores de una prueba de CTG, sea capaz de identificar automáticamente si un feto se encuentra en estado patológico para permitir una intervención médica inmediata.

3.- Defina un experimento completo

(dataset, tipo de entrenamiento, definición de modelos, definición de métricas de comparación). Espere la aprobación del profesor antes de seguir.

1. Dataset y Variable Objetivo

- Usaremos la Clasificación Multiclase usando la variable NSP (Fetal State) como target. Esta variable clasifica el estado en 3 clases: Normal, Sospechoso y Patológico.
- **Por qué:** El dataset permite clasificar 10 patrones morfológicos o 3 estados fetales. El enfoque de 3 clases (NSP) es el estándar en la literatura clínica porque responde a la urgencia médica real. Además.

Se aplicará una técnica de manejo de desbalanceo (como SMOTE o ajuste de pesos de clase), ya que la clase "Normal" domina fuertemente el dataset (1655 casos frente a 176 patológicos).

2. Tipo de Entrenamiento

- **Solución:** Aprendizaje Supervisado (Supervised Learning) utilizando una separación *Train/Test Split* (ej. 80/20) combinada con **Stratified K-Fold Cross Validation** (Validación Cruzada Estratificada) con K=5 o K=10.
- **Por qué:** Es supervisado porque ya tienes las etiquetas médicas históricas. La validación cruzada *estratificada* es obligatoria aquí: garantiza que en cada iteración de prueba se mantenga la proporción real de fetos normales, sospechosos y patológicos, evitando que el modelo se entrene con un lote donde, por azar, no haya ningún caso patológico.

3. Definición de Modelos (Los Competidores)

- Proponer una comparativa entre 3 algoritmos de diferente naturaleza:
 1. *Regresión Logística (Multinomial)*: Como tu modelo base (baseline) estadístico.
 2. *Random Forest*: Como modelo de ensamble basado en árboles.
 3. *Support Vector Machine (SVM)* o *XGBoost/LightGBM*: Como modelo avanzado.
- **Por qué:** En los experimentos de Machine Learning, es una mala práctica probar un solo modelo complejo. Inicias con Regresión Logística para ver si el problema se puede resolver de manera simple. Random Forest suele ser el mejor

algoritmo todoterreno para datos tabulares clínicos, y algoritmos como SVM o LightGBM suelen exprimir al máximo la precisión en las clases minoritarias.

4. Definición de Métricas de Comparación

- Evaluar los modelos basándose en el **F1-Score (Macro)**, el **Recall (Sensibilidad)** de la clase "Pathologic" y el análisis de la **Matriz de Confusión**. Excluir el *Accuracy* (Exactitud) como métrica principal.
- **Por qué:** En el contexto médico, no nos podemos equivocar con las predicciones por lo que no se tolerarán muchos falsos positivos, en base a esto usaremos el recall como métrica. El *Accuracy* miente. Si el 78% de los datos son fetos normales, un modelo mediocre que siempre prediga "Normal" obtendrá un 78% de exactitud, pero dejará morir al 100% de los fetos enfermos. El **Recall** en la clase patológica es la métrica de oro: médicamente hablando, es mucho mejor equivocarse asustando a un paciente sano (falso positivo) que mandar a su casa a un paciente en estado patológico (falso negativo). El F1-Score Macro te dará un promedio general justo.

4.- Implemente su experimento.

5.- Presente resultados de forma ordenada

6.- Analice los resultados obtenidos

7.- Puede usar un jupyter notebook en colab para una ejecución más rápida del proceso de entrenamiento, pero la entrega debe ser un link a repo github. Todos los integrantes suben su versión.